

Dataset	Outliers	k optimal	Inertie (k)	ARI (max)	Analyse quantitative
Iris	Non	3-4	158,55		0,83 Bonne inertie et ARI élevé à k=3–4
Iris	Oui	3-4	162,17		0,83 Inertie légèrement augmentée, ARI stable
Wine	Non		3	1083,41	ND Bonne chute d'inertie à k=3
Breast Cancer	Non		2	8466,6	0,76 Chute nette à k=2 ; ARI élevé
Breast Cancer	Oui		2	11767,94	0,74 Inertie + haute, ARI baisse légèrement
Mall Customers	Non	4-5	169,06	ND	Réduction continue de l'inertie jusqu'à k=5

Pour évaluer les résultats du clustering avec KMeans, il faut distinguer deux cas : les jeux de données qui ont des étiquettes (comme Iris ou Breast Cancer), et ceux qui n'en ont pas.

Quand le dataset contient des vraies étiquettes (ou "labels"), on peut utiliser une mesure appelée Adjusted Rand Index (ARI). Cette valeur permet de savoir si les clusters trouvés sont proches des vraies étiquettes.

En revanche, pour des données sans étiquettes comme Mall Customers ou Wine, on ne peut pas calculer l'ARI. On doit donc se baser uniquement sur l'inertie.

Un autre point important, c'est le traitement des outliers (valeurs extrêmes). En général, enlever les outliers améliore l'ARI, car cela rend les clusters plus nets.

Au final, le choix du bon k (nombre de clusters) ne se fait pas uniquement avec un seul critère. Il faut combiner plusieurs approches :

D'abord, l'inertie, qui donne une idée quantitative de la cohésion des groupes.

Ensuite, l'ARI, si on a des étiquettes, pour évaluer objectivement le résultat.

Et enfin, la visualisation, pour voir si les clusters ont du sens visuellement (ex. : bien séparés, formes logiques, pas de confusion).

Analyse qualitative

Clustering bien aligné avec les classes ; >4 = sur-segmentation

Clustering toujours bon mais moins net ; impact des outliers

Clusters interprétables à $k=3$; bruit visuel au-delà

Bon découpage binaire (malin/bénin) ; >2 = clusters flous

Plus de bruit, cohésion des clusters réduite

Clustering raisonnable à $k=4-5$; >5 = sur-fragmentation visuelle

et ceux qui n'en ont pas (comme Mall Customers ou Wine).

si les clusters trouvés par l'algorithme ressemblent aux vraies classes. Par exemple, dans les jeux de données Iris et Breast Cancer, l'ARI nous donne une idée de la qualité (c'est-à-dire la compacité des clusters) et la visualisation des résultats. On utilise souvent la méthode du "coude" (elbow method) pour choisir le bon nombre de clusters et plus faciles à séparer. Par contre, l'inertie peut augmenter, car sans les valeurs extrêmes, les distances internes aux clusters deviennent plus importantes.

laire de la qualité du regroupement. Plus l'ARI est proche de 1, plus le clustering est fidèle aux vraies catégories.

re de clusters k . Mais cela reste assez subjectif : on regarde où la courbe de l'inertie commence à se stabiliser, mais l'interprétation peut varier selon